操作系统 Operating Systems

L17 信号量临界区保护

Critical Section

授课教师：李治军
lizhijun_os@hit.edu.cn
综合楼404室

温故而知新：什么是信号量？通过对这个量的访问和修改，让大家有序推进。哪里还有问题吗？

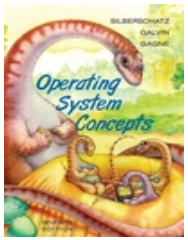

共同修改信号量引出的问题

初始情况

```
empty = -1;
```

这是什么含义?

```
Producer(item) {
    P(empty);
    ...}
```

一个可能的执行(调度)

```
P1.register = empty;
P1.register = P1.register - 1;
P2.register = empty;
P2.register = P2.register - 1;
empty = P1.register;
empty = P2.register;
```

最终的empty等于多少?对吗?

生产者P_1

```
register = empty;
register = register - 1;
empty = register;
```

生产者P_2

```
register = empty;
register = register - 1;
Empty = register;
```

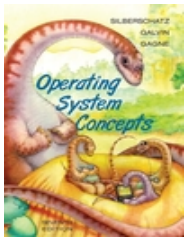

竞争条件(Race Condition)

- **竞争条件:** 和调度有关的共享数据语义错误

第i次执行	第j次执行
P_1.register = empty;	P_1.register = empty;
P_1.register = P_1.register - 1;	P_1.register = P_1.register - 1;
P_2.register = empty;	empty = P_1.register;
P_2.register = P_2.register - 1;	P_2.register = empty;
empty = P_1.register;	P_2.register = P_2.register - 1;
empty = P_2.register;	empty = P_2.register;

- 错误由多个进程并发操作共享数据引起
- 错误和调度顺序有关，难于发现和调试

问题：右面的图这两个人的方法有效果吗?

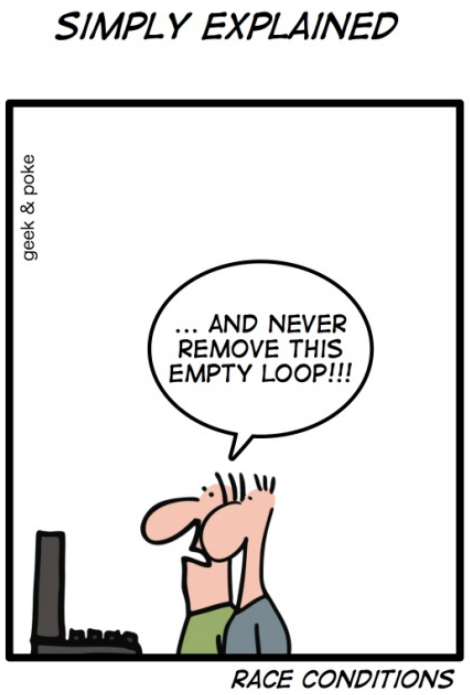

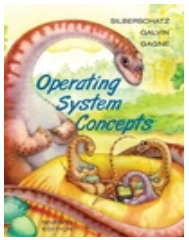

解决竞争条件的直观想法

- 在写共享变量empty时阻止其他进程也访问empty

生产者P_1

检查并给empty上锁

P_1.register = empty;

P_1.register = P_1.register - 1;

生产者P_2

检查empty的锁 ?

生产者P_1

empty = P_1.register;

给empty开锁

生产者P_2

检查并给empty上锁

P_2.register = empty;

P_2.register = P_2.register - 1;

empty = C.register;

给empty开锁

一段代码一次只允许一个进程进入

仍是那个执行序列

P_1.register = empty;

P_1.register = P_1.register - 1;

P_2.register = empty;

P_2.register = P_2.register - 1;

empty = P_1.register;

empty = P_2.register;

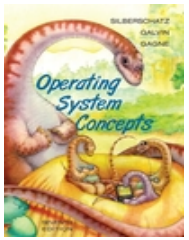

临界区(Critical Section)

- 临界区: 一次只允许一个进程进入的该进程的那一段代码

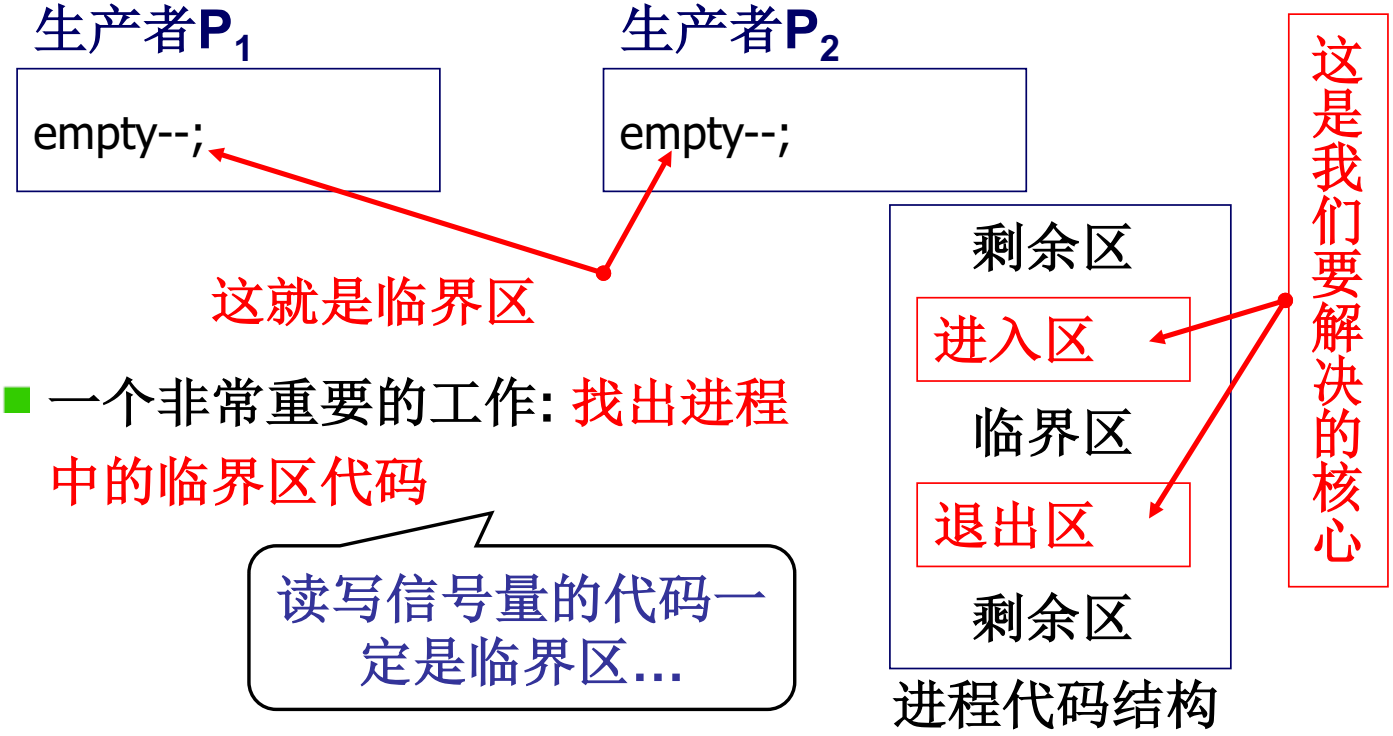

- 一个非常重要的工作: 找出进程中的临界区代码

读写信号量的代码一定是临界区...

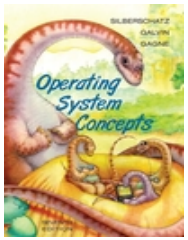

临界区代码的保护原则

- 基本原则：互斥进入: 如果一个进程在临界区中执行，则其他进程不允许进入
  - 这些进程间的约束关系称为互斥(mutual exclusion)
  - 这保证了是临界区
- 好的临界区保护原则
  - 2. 有空让进: 若干进程要求进入空闲临界区时，应尽快使一进程进入临界区
  - 3. 有限等待: 从进程发出进入请求到允许进入，不能无限等待

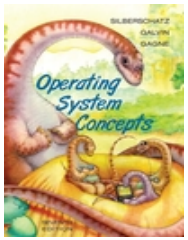

进入临界区的一个尝试 – 轮换法

```
while (turn !=0) ;
    临界区
turn = 1;
    剩余区
```

进程P_0

```
while (turn !=1) ;
    临界区
turn = 0;
    剩余区
```

进程P_1

- 问题: P_0完成后不能接着再次进入，尽管进程P_1不在临界区…(不满足有空让进)
- 满足互斥进入要求

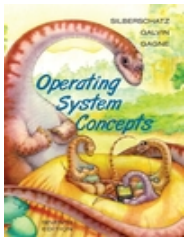

进入临界区的又一个尝试

- 似乎没有任何头绪… 可借鉴生活中的道理

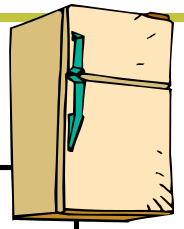

时间	丈夫	妻子
3:00	打开冰箱，没有牛奶了	
3:05	离开家去商店	
3:10	到达商店	打开冰箱，没有牛奶了
3:15	买牛奶	离开家去商店
3:20	回到家里，牛奶放进冰箱	到达商店
3:25		买牛奶
3:30		回到家里，牛奶放进冰箱

- 上面的轮换法类似于什么？值日
- 更好的方法应该是立即去买，留一个便条

许多复杂的道理往往就埋藏在日常生活中！

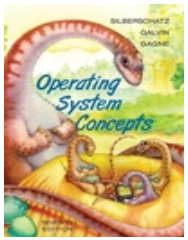

进入临界区的又一个尝试 – 标记法

```
if(noMilk){
  if(noNote){
     leave Note;
     buy milk;
     remove note;
   }
}
```

计算机考虑问题的方式

```
leave Note;
if(noMilk){
  if(noNote){
     buy milk;
   }
}
remove note;
```

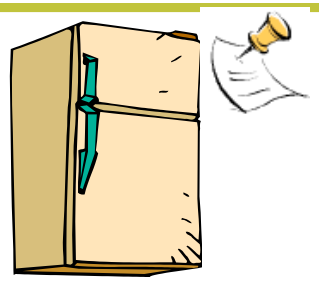

```
flag[0] = true;
while (flag[1]) ;
```

临界区

```
flag[0] = false;
```

剩余区

进程P_0

```
flag[1] = true;
while (flag[0]) ;
```

临界区

```
flag[1] = false;
```

剩余区

进程P_1

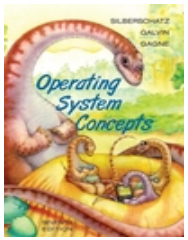

标记法能否解决问题?

- 考虑下面的执行顺序

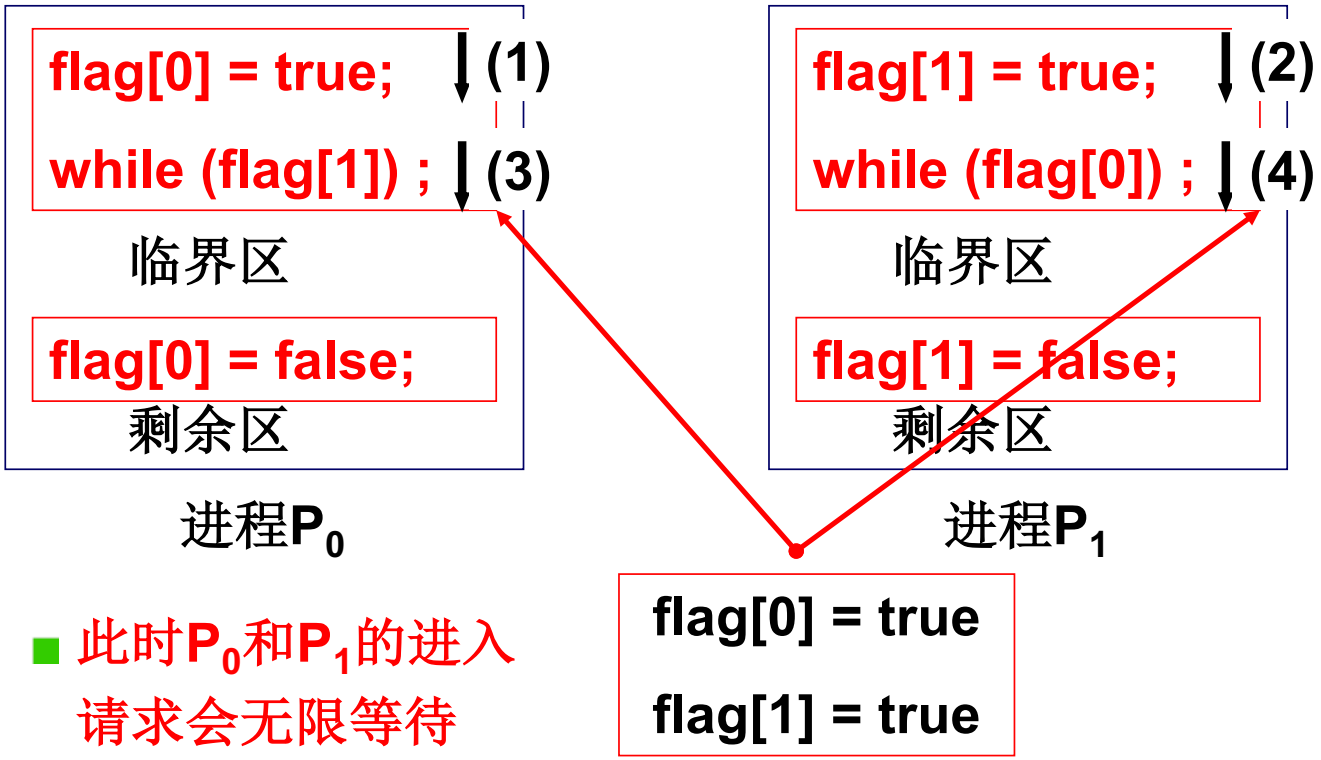

- 此时P_0和P_1的进入请求会无限等待

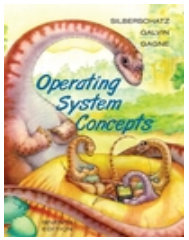

进入临界区的再一次尝试 – 非对称标记

- 带名字的便条 + 让一个人更加勤劳

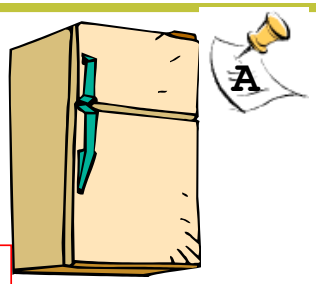

丈夫(A)

```
leave note A;
while (note B)
{  //X
    do nothing;
}
if (noMilk) {
    buy milk;
}
remove note A;
```

妻子(B)

```
leave note B;
if (noNote A)
{  //Y
   if(noMilk){
      buy milk;
   }
}
remove note B;
```

丈夫是那个更勤劳的人

各种情况都正确

- 关键: 选择一个进程进入，另一个进程循环等待

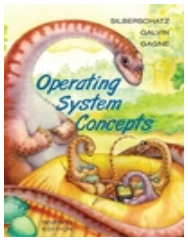

进入临界区Peterson算法

- 结合了标记和轮转两种思想

```
flag[0] = true;
turn = 1;
while (flag[1] && turn == 1) ;
    临界区
flag[0] = false;
    剩余区
```

进程P_0

```
flag[1] = true;
turn = 0;
while (flag[0] && turn == 0) ;
    临界区
flag[1] = false;
    剩余区
```

进程P_1

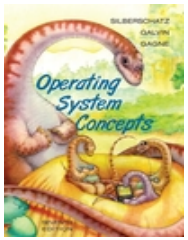

Peterson算法的正确性

- 满足互斥进入:

  如果两个进程都进入，则flag[0]=flag[1]=true，turn==0==1，矛盾!

- 满足有空让进:

  如果进程P_1不在临界区，则flag[1]=false，或者turn=0，都P_0能进入!

- 满足有限等待:

  P_0要求进入，flag[0]=true；后面的P_1不可能一直进入，因为P_1执行一次就会让turn=0。

```
flag[i] = true;
turn = j;
while (flag[j] && turn == j) ;
        临界区
flag[i] = false;
        剩余区
```

进程P_i

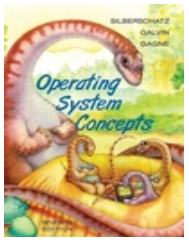

多个进程怎么办? – 面包店算法

- 仍然是标记和轮转的结合
  - 如何轮转: 每个进程都获得一个序号，序号最小的进入
  - 如何标记: 进程离开时序号为0，不为0的序号即标记
  - 面包店: 每个进入商店的客户都获得一个号码，号码最小的先得到服务；号码相同时，名字靠前的先服务。

进程 P_i

```
choosing[i] = true; num[i] = max(num[0], …, num[n-1])+1;
choosing[i] = false; for(j=0; j<n; j++) { while(choosing[j]);
while ((num[j] != 0) && (num[j], j)<(num[i], i])); }
        临界区
num[i] = 0;
        剩余区
```

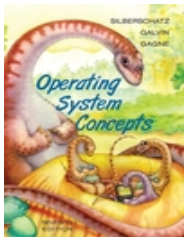

面包店算法的正确性

进程 P_i

```
choosing[i] = true; num[i] = max(num[0], …, num[n-1])+1;
choosing[i] = false; for(j=0; j<n; j++) { while(choosing[j]);
while ((num[j] != 0) && (num[j], j)<(num[i], i])); }
        临界区
num[i] = 0;
```

- 互斥进入: P_i在临界区内，P_k试图进入，一定有(num[i], i)<(num[k],k)，P_k循环等待。
- 有空让进: 如果没有进程在临界区中，最小序号的进程一定能够进入。
- 有限等待: 离开临界区的进程再次进入一定排在最后(FIFO)，所以任一个想进入进程至多等n个进程

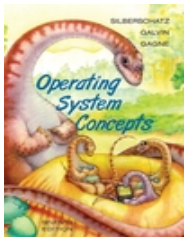

一个显然的感觉是: 太复杂了，有没有简单一些的...

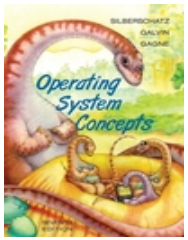

临界区保护的另一类解法...

- 再想一下临界区：只允许一个进程进入，进入另一个进程意味着什么？
  - 被调度: 另一个进程只有被调度才能执行，才可能进入临界区，如何阻止调度?

```
cli();

    临界区

sti();

    剩余区
```

进程P_i

- 什么时候不好使?
- 多CPU(多核)...

  问题：为什么不好使?

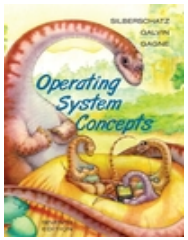

临界区保护的硬件原子指令法

```
boolean
   TestAndSet(boolean &x)
{
    boolean rv = x;
    x = true;
    return rv;
}
```

一次执行完毕

```
while(TestAndSet(&lock)) ;
```

临界区

```
lock = false;
```

剩余区

进程P_i

- 想一想: 多CPU情况好不好使?